

C 题建模试跑与数据缺口报告

更新日期：2026-08-17

结论摘要

现有政府数据足以完成趋势可视化、疫情断点识别和一组透明的基准回归，但还不足以支撑可信的 2026—2030 年点预测，更不足以从数据中识别政策投入、客源变化和新业态的因果效应。

最核心的问题不是模型复杂度，而是因变量在最关键的疫情与恢复阶段成块缺失：游客量缺 2020、2021、2022、2025 年，旅游综合收入缺 2016、2020、2022、2025 年。剔除 2020—2022 年异常期后，疫情后常态观测只有 2023、2024 两年，因此“长期增长”“疫情后水平损失”和“恢复速度”无法同时由数据估计。

本次试跑给出两套结果：

- 1. **统计外推基准**：疫情后水平断点的对数线性回归，提供参数检验和条件于模型成立的 95% 预测区间；
- 2. **规划情景基准**：以 2025 年政府目标作为临时锚点，以 2026 年政府工作报告提出的旅游综合收入增长 8% 作为基准假设。它更适合做规划算例，但不是统计置信区间，也不能替代 2025 年实际值。

建议论文现阶段把统计外推结果称为“恢复性高增长上界基准”，把政策锚定结果称为“规划基准情景”，不要把前者直接写成唯一预测结论。

1. 数据审计

建模读取 `official_annual_summary_2010_2025.csv` 。实际值、目标值、累计值和推导值的口径规则见 `README.md` 。

指标	2010—2025 有值年份	覆盖率	缺失年份	含推导、 缓存或预计值的年份数
旅游接待人次	12/16	75.00%	2020、2021、2022、 2025	1
旅游综合收入	12/16	75.00%	2016、2020、2022、 2025	3
GDP	15/16	93.75%	2017	5
第三产业增加值	11/16	68.75%	2012、2015—2018	1

还存在三个不能用“补缺”掩盖的口径问题：

- 旅游直接收入与旅游综合收入是不同指标，历史上约相差 5 倍，不能拼接；
- 2025 年 2800 万人次、231 亿元是目标，不是年度实际；2021—2025 年 1.05 亿人次、792.5 亿元是五年累计，也不能拆成年度实际；

- GDP、社零等序列存在统计制度或核算口径断点，名义旅游收入也尚未按价格指数折算为不变价。

因此本次没有对 2020—2022 年做普通线性插值。该段缺失与疫情强相关，属于非随机缺失；直接插值会系统性压低冲击幅度并高估模型精度。

2. 模型设计

2.1 问题 1 的简单增长模型

对 2010—2019 年非疫情样本分别拟合指数增长模型：

$$\log Y_t = \alpha + \beta(t - 2010) + \varepsilon_t,$$

其中，游客量估计年增长率为 $\exp(0.13443) - 1 = 14.39\%$ ，综合收入估计年增长率为 $\exp(0.16964) - 1 = 18.48\%$ 。游客量与收入的对数尺度 R^2 分别为 0.9874 和 0.9920，说明该模型能很好描述 2010—2019 年的扩张阶段。

但这一模型不能跨制度断点直接外推：若机械延续到 2030 年，将得到 1.322 亿人次和 1128.4 亿元，显著放大长期增长。它适合刻画疫情前增长，不适合作为当前唯一预测模型。

2.2 主模型：疫情后水平断点的对数线性回归

主模型为：

$$\log Y_t = \alpha + \beta(t - 2010) + \delta I(t \geq 2023) + \varepsilon_t.$$

样本保留 2010—2019、2023—2024 年，排除 2020—2022 年常态趋势估计。收入的 2021 年实际值 110 亿元用于冲击诊断，但不用于估计正常增长斜率。与 ARIMA 相比，这个模型参数少、解释直接，也允许年度缺失；当前每个序列只有约 12 个有效点，尚不足以可靠选择多个 AR、MA 阶数。

指标	有效样本量	年趋势 β	年增长率	疫情后水平项 δ	对数 R^2	MAPE	JB 正态性检验 p 值	DW
游客量	12	0.13430	14.37%	-0.79107	0.9893	3.39%	0.7590	2.154
综合收入	11	0.16947	18.47%	-0.59790	0.9951	3.57%	0.7039	1.395

两个年趋势和两个疫情后水平项的双侧 t 检验均为 $p < 0.001$ 。断点项对应的相对水平变化约为游客量 -54.7%、综合收入 -45.0%，含义是 2023—2024 年水平低于“疫情前指数趋势的同期反事实”，并不表示相对 2019 年实际下降同样幅度。

残差正态性未被 Jarque—Bera 检验拒绝，但小样本下该检验功效很低。更重要的是，这些诊断只检验给定回归形式的样本内残差，不能验证 14%—18% 的高增长能持续到 2030 年。

严格证据子样本进一步排除了缓存、同比反推和政府站辅助附件值。2030 年预测相对主模型变化为游客量 -0.5%、综合收入 -3.8%，说明当前最大的风险不是个别低等级观测，而是模型结构和疫情后样本过少。

3. 统计外推结果

下表给出主模型的点预测和 **95% 单次预测区间**。预测区间包含回归残差，不只是均值置信区间，但仍然条件于“疫情前年增长斜率在未来保持不变”这一强假设。

年份	游客量预测（万人次）	95% 预测区间	综合收入预测（亿元）	95% 预测区间
2026	3496.2	[3066.0, 3986.7]	314.3	[273.0, 361.7]
2027	3998.7	[3496.2, 4573.4]	372.3	[322.4, 429.9]
2028	4573.4	[3983.3, 5251.0]	441.0	[380.3, 511.5]
2029	5230.8	[4534.5, 6034.0]	522.5	[448.2, 609.1]
2030	5982.6	[5158.2, 6938.9]	619.0	[527.8, 725.9]

合理性检验

主模型对缺失的 2025 年预测为 3056.8 万人次和 265.3 亿元，分别比 2025 年政府目标高 9.2% 和 14.8%。若再与 2021—2025 年累计 792.5 亿元联立，已知的 2021、2023、2024 年收入合计 522.5 亿元，则只给 2022 年留下 4.7 亿元。这不是逻辑矛盾，但对年度值的轻微改动会造成 2022 年隐含值剧烈变化，显示累计约束无法替代年度实际。

此外，主模型收入年增长率为 18.47%，而 2026 年蓟州区政府工作报告提出“全年旅游综合收入增长 8%”。两者差异较大。因此统计外推更接近“重新回到疫情前扩张速度”的高增长路径，不宜直接命名为自然延续基准。

模型对比也显示结构不确定性很大：2030 年游客量在无断点模型、主模型、疫情前模型下分别为 5398、5983、13224 万人次；综合收入分别为 568、619、1128 亿元。主模型自身的 95% 区间没有覆盖全部模型结构差异，不能解释为总预测不确定性。

4. 政策锚定的规划情景

为了得到更适合讨论的规划算例，使用以下显式假设：

- 以 2025 年目标 2800 万人次、231 亿元作为临时锚点；
- 基准情景：综合收入年增 8%，名义人均次消费年增 3%；
- 乐观情景：综合收入年增 12%，名义人均次消费年增 4%；
- 悲观情景：2026 年综合收入一次性下降 15%，之后年增 5%，人均次消费年增 2%；
- 使用恒等式 $R_t = V_t S_t / 10000$ ，其中 S_t 为元/人次。

情景	2026 游客量 / 收入	2027	2028	2029	2030
基准	2935.9 / 249.5	3078.4 / 269.4	3227.9 / 291.0	3384.6 / 314.3	3548.9 / 339.4
乐观	3015.4 / 258.7	3247.3 / 289.8	3497.1 / 324.5	3766.1 / 363.5	4055.8 / 407.1
悲观	2333.3 / 196.4	2402.0 / 206.2	2472.6 / 216.5	2545.3 / 227.3	2620.2 / 238.7

表中游客量单位为万人次，收入单位为亿元。这三条路径是情景假设，不是由历史数据估计出的政策因果效应，也没有 95% 置信含义。拿到 2025 实际值后应首先替换锚点。

5. 敏感性结论

收入恒等式给出局部敏感性：

$$\frac{\Delta R}{R} \approx \frac{\Delta V}{V} + \frac{\Delta S}{S}.$$

因此在其他条件不变时，游客量提高 1% 或人均次消费提高 1%，综合收入都约提高 1%。基准情景中收入年增 8%、人均次消费年增 3%，隐含游客量年增约 $1.08/1.03 - 1 = 4.85\%$ 。这说明“提高留宿率、停留时间和消费转化”与“单纯拉新客”在收入目标上具有同阶影响。

但是，现有数据不能估计“财政投入增加 1% 会使游客量增加多少”“外省客占比提高 1 个百分点会使人均消费增加多少”或“新增一个项目的边际收入”。这些参数需要连续的投入、项目、客源和消费结构数据，并最好有对照地区。

6. 数据缺口清单

P0：补齐后才能形成可信预测

缺口	最低需要的数据	影响
疫情与恢复期年度实际	2020—2022 年游客量和综合收入；2021 年精确游客量；2025 年实际值	无法分离疫情冲击、恢复速度和长期趋势，是当前最大缺口
2016 年综合收入	同口径年度实际及来源原表	收入序列中间断点，限制增长率与单位消费分析
指标口径元数据	人次是否含重复到访、全域/景区范围、统计调查方法、修订历史	口径变化可能被模型误判为经济波动
不变价收入	旅游收入平减指数，或可匹配的 CPI 服务类分项	当前收入增长混合了实际消费增长与价格上涨

P1：补齐后才能做时间序列与政策敏感性

缺口	建议粒度与字段	可支持模型
高频旅游结果	至少 2019—2025 的月度游客量、收入、景区客流；最好 60 个以上连续月	SARIMA/ETS、节假日效应、疫情干预模型、滚动回测

缺口	建议粒度与字段	可支持模型
客源与行为结构	京津冀/外省占比、日游/过夜、平均停留天数、复游率、分客群人均消费	将收入拆成客流、留宿和消费，识别真正驱动因素
旅游专项投入	年/月预算与实际支出、项目金额、开工投产时间、营销投放	估计政策投入弹性和滞后效应；现有“文化旅游体育与传媒支出”不是旅游专项投入
供给能力	景区承载量、床位/客房、入住率、民宿数量、A级景区及项目投产	估计饱和上限，避免指数模型无限增长
交通与可达性	自驾流量、铁路/公交客运、停车容量、京津到达时间	解释客流变化并量化交通项目效果
外部冲击日历	管控期、景区关闭、极端天气、重大节庆赛事、法定假日天数	构建干预变量，防止异常冲击污染趋势

P2：补齐后才能做稳健因果分析

- 2012、2015—2018 年第三产业增加值最终核实值，2017 年 GDP 最终值，以及 2019 年 GDP 口径断点说明；
- 天津其他区、北京近郊区县或河北相似县区的同口径旅游面板数据，用于双重差分、合成控制或相对趋势校验；
- 北京、天津客源市场的收入、人口、搜索热度、在线预订和油价等外生变量；
- 每项“十五五”政策的明确实施时间、投入强度、覆盖对象和可量化结果指标。

7. 当前可交付边界

现有数据可以支持：疫情前增长率估计、2023 年后的水平断点检验、基于强假设的区间外推、五年累计约束校验和透明情景算例。

现有数据不宜支持：高阶 ARIMA 模型选择、精确的 95% 总不确定性区间、政策投入因果弹性、承载力上限估计，以及把 2026—2030 年某一条曲线写成高可信唯一预测。

8. 复现方法

运行：

```
python3 code/scripts/model_jizhou_tourism.py
```

脚本输出在 outputs/jizhou_tourism_model/，包括参数估计、诊断、全部模型预测、规划情景、缺失审计、五年累计约束和趋势图。脚本只依赖 NumPy、pandas 和 matplotlib；不会覆盖原始政府数据。