

蓟州区旅游经济数据预处理与模型选择建议

更新日期：2026-08-17

数据范围：2010—2025 年

核心输

入： official_annual_summary_2010_2025.csv 、 supplemental_gap_evidence_2016_2025.csv 、
official_tourism_supply_observations_2012_2024.csv 、 official_related_observations_2014_2025.csv

一、结论摘要

更新后的数据显著改善了 GDP、第三产业增加值以及住宿供给、财政和道路等辅助变量的覆盖，但旅游核心因变量仍存在成块缺失：游客量缺 2020、2021、2022、2025 年，旅游综合收入缺 2016、2020、2022、2025 年。由于缺失集中在疫情冲击和恢复阶段，属于与事件机制相关的非随机缺失，不能用均值或普通线性插值直接覆盖。

本轮因此保留两套数据：

- 1. **严格观测层**：保持官方优选表原有空值，用于证据审计、正式描述统计和严格样本建模；
- 2. **建模补全层**：利用累计约束、目标隐含基数、同口径供给代理和二手锚点生成连续序列，只用于模型连续性、约束校验和敏感性分析，不得写成官方实测。

补全后，游客量和综合收入的建模序列均为 16/16 年完整覆盖；GDP 和第三产业增加值原本已为 16/16。共生成或引入 8 个非官方优选值。异常检测在对数同比尺度完成，异常年份集中于 2019—2023 年，全部保留，不做删除或缩尾。

最终模型建议是“三层架构”：

- 历史解释采用质量分层的稳健分段回归；
- 2026—2030 点预测以原值 Ridge 为低方差数据基准，政策锚定路径作为规划基准，对数断点/BayesianRidge 作为乐观上界；
- 政策敏感性采用收入恒等分解、情景树与拉丁超立方 Monte Carlo，而不是在现有小样本上强行估计政策因果弹性。

二、缺失值处理

2.1 缺失审计

指标	原始有效年份	原始缺失年份	建模补全后	处理原则
游客量	12/16	2020、2021、2022、2025	16/16	疫情期使用冲击代理与累计约束；2025 使用二手锚点
旅游综合收入	12/16	2016、2020、2022、2025	16/16	同比反推、冲击代理、目标隐含值与累计约束分别标记
GDP	16/16	无	16/16	保留 2019 年口径断点标记
第三产业增加值	16/16	无	16/16	保留 2019 年口径断点标记

没有采用均值填充。均值会破坏长期趋势并人为压低方差；普通线性插值会把疫情冲击平滑掉。KNN 也没有作为主补全方法，因为只有 16 个年度样本，游客量与综合收入在疫情阶段同时缺失，且住宿供给在 2016—2017 年存在名录或统计范围断点，距离关系不稳定。KNN 可以作为补充敏感性，但不能替代约束与事件机制。

2.2 建模补全规则

年份	指标	建模值	范围	依据与公式	数据角色
2016	综合收入	108.7866 亿元	104.0— 113.8	2017 年约 130 亿元及增长 19.5%，反推 $130/1.195$ ； 范围用于处理两个发布数均取整造成的不确定性	代数反推， 仅诊断
2020	游客量	2426.1594 万人次	2265.2— 2598.5562	以 2019 年为基准，活动系数为 $\text{sqrt}(\text{客房收入比}\times\text{社零指数})=\text{sqrt}(6068/6538.4\times0.809)=0.86649$ ； 上下界分别取两个代理指数	冲击代理情景
2020	综合收入	142.9701 亿元	133.485— 153.1292	与游客量使用相同本地活动系数，保持 2019 年人均次消费不变	冲击代理情景
2021	游客量	1779.4786 万人次	1698.7359 — 1860.2213	2021—2022 合计约束为 2803；2021 分配份额取客房收入份额 60.60% 与综合收入代理份额 66.37% 的等权平均 63.48%	累计约束补全
2022	游客量	1023.5214 万人次	942.7787 — 1104.2641	2803-2021补全值 ；上下界与两种分配代理相对应	累计约束补全
2022	综合收入	55.7491 亿元	50—65	由 2023 年 160 亿元目标及“增长 187%” 隐含基数反推： $160/(1+1.87)$	目标隐含值， 仅诊断
2025	游客量	2691 万人次	2600— 2800	二手报道年度值；上界覆盖政府目标 2800， 范围仅用于锚点敏感性	二手锚点
2025	综合收入	214.2509 亿元	200—231	五年累计中 2022 与 2025 的余量为 270；扣除 2022 情景值后得到 214.2509；范围由“突破 200 亿元”下界和 231 亿元目标上界限定	累计约束情景

这些范围均是**敏感性区间**，**不是统计置信区间**。正式论文应同时报告严格观测模型和补全情景模型；若两者结论差异较大，应把差异本身作为数据不确定性结果。

2.3 处理后核心数据

年份	游客量（万人次）	游客角色	综合收入（亿元）	收入角色	人均次消费（元）
2010	848.000	官方优选	35.521	官方优选	418.883
2011	1098.600	官方优选	46.000	官方优选	418.715
2012	1152.000	官方优选	52.000	官方优选	451.389
2013	1295.000	官方优选	63.200	官方优选	488.031
2014	1553.400	官方优选	79.000	官方优选	508.562
2015	1818.720	官方优选	94.000	官方优选	516.847
2016	2086.000	官方优选	108.787	代数反推	521.508
2017	2392.000	官方优选	130.000	官方优选	543.478
2018	2660.000	官方优选	142.000	官方优选	533.835
2019	2800.000	官方优选	165.000	官方优选	589.286

年份	游客量（万人次）	游客角色	综合收入（亿元）	收入角色	人均次消费（元）
2020	2426.159	冲击代理情景	142.970	冲击代理情景	589.286
2021	1779.479	累计约束补全	110.000	官方优选	618.159
2022	1023.521	累计约束补全	55.749	目标隐含值	544.679
2023	2363.000	官方优选	191.500	官方优选	810.410
2024	2643.000	官方优选	221.000	官方优选	836.171
2025	2691.000	二手锚点	214.251	累计约束情景	796.176

三、异常值检测与处理

3.1 方法

旅游与宏观指标具有明显趋势，直接对水平值使用箱线图容易把正常增长误判为异常。因此先计算对数同比：

$$g_t = \ln \left(\frac{x_t}{x_{t-1}} \right).$$

然后同时使用：

$$z_t = \frac{g_t - \bar{g}}{s_g}, \quad |z_t| > 3 \text{ 判为异常};$$

$$g_t < Q_1 - 1.5IQR \text{ 或 } g_t > Q_3 + 1.5IQR \text{ 判为异常}.$$

双方法并用的原因是：Z-score 对近似正态分布直观，但小样本下易受极端点影响；IQR 对分布形态要求较低，更适合 15 个增长率观测。最终标记取二者并集。

3.2 检测结果

共标记 11 个“年份—指标”异常，涉及 2019、2020、2021、2022、2023 五个年份：

- 2019 年 GDP 和第三产业增加值下降约 42%，Z-score 约为 -3.48，主要反映统计核算或制度口径断点，不能直接解释为真实经济崩落；
- 2020—2022 年游客量、收入显著下降，属于疫情冲击和补全情景共同体现的结构变化；
- 2023 年游客量、收入和人均次消费出现恢复性跳升，其中综合收入同比约 243.5%，反映低基数与恢复阶段；
- 2022 年人均次消费下降、2023 年人均次消费上升，均受游客量和收入补值共同影响，解释时需降级使用。

3.3 保留、修正或删除

所有异常值均保留，不做删除、Winsor 缩尾或中位数替换，原因如下：

1. 这些年份对应真实外部冲击、统计制度变化或恢复过程，是赛题要解释的信息；
2. 删除后会产生选择性样本并夸大常态增长的稳定性；
3. 修正会把人为假设再次叠加到已经补全的年份，降低可审计性。

处理方式是在模型中加入 pandemic_dummy、recovery_dummy、macro_scope_break_dummy 和供给口径断点标记，并分别进行严格样本、补全样本和上下界敏感性分析。

四、转换处理

4.1 自然对数

$$x^{(\log)} = \ln x.$$

适用于指数增长、Gompertz、弹性模型和对数线性回归，可缓解异方差并将乘法增长转为加法。核心变量均为正，因此不存在零值取对数问题。

4.2 Z-score 标准化

$$z_i = \frac{x_i - \mu_x}{\sigma_x}.$$

Ridge、Lasso、SVM、PCA、KNN 等受量纲或正则化影响的模型需要标准化。树模型通常不需要。正式滚动回测时，均值和标准差必须仅在当前训练窗内拟合，不能先用 2010—2025 全样本标准化，否则产生前视泄漏。

4.3 Min-Max 归一化

$$x'_i = \frac{x_i - x_{\min}}{x_{\max} - x_{\min}}.$$

适合神经网络、距离模型和综合评价可视化，但对异常值和未来新极值敏感。本题年度样本少，不建议把需要 Min-Max 的复杂模型作为主模型；归一化列主要用于备选算法和图表比较。

建模 CSV 已对游客量、综合收入、GDP、第三产业增加值和人均次消费分别提供原值、ln_、z_ 和 minmax_ 列。

五、数据补充建议

5.1 必须补充

1. **2020—2022、2025 年游客量与综合收入官方精确实际值**：这是区分疫情冲击、恢复速度和长期趋势的决定性信息。优先向蓟州区统计局、文旅局查询统计年鉴原表，必要时提交政府信息公开申请。
2. **2016 年同口径旅游综合收入**：当前 108.7866 亿元来自取整值反推，不能关闭证据缺口。
3. **指标定义和修订历史**：至少确认全域/景区范围、重复到访处理、旅游直接收入与综合收入定义、调查方法及修订记录。
4. **旅游收入平减指数**：现有收入是名义值，建议从国家统计局或天津市统计局取得服务类 CPI、文娱旅游分项或可替代价格指数，形成不变价收入。

5.2 可选补充

- 至少 60 个连续月的游客量、收入、景区客流和酒店入住率，用于 SARIMAX、ETS 和干预时间序列；
- 客源地、过夜率、停留时长、复游率和分客群消费，用于拆解客流、留宿与消费机制；
- 旅游专项投入、项目投产时间和营销曝光，用于估计政策滞后效应；
- 交通流量、停车、铁路/公交客运与极端天气事件，用于解释可达性和外部冲击；
- 相似区县面板，用于双重差分、合成控制和相对趋势校验。

官方优先入口包括蓟州区政府数据发布、天津统计年鉴和天津市文旅局统计信息。EPS、中经网可作为年鉴回列与交叉核验渠道。Kaggle 更适合算法练习或通用旅游数据特征设计，不应拿来替代蓟州区官方核心数据。

六、两份建模方案评价

6.1 机器学习试验报告

优点：

- 明确认识到每个目标只有 12 个官方年度标签，拒绝用复杂算法制造虚假精度；
- 使用 expanding-origin 滚动验证，避免随机切分时间序列；
- 将标准化和调参限制在训练折内，防止前视泄漏；
- 设置 Random Forest、RBF-SVR、Gaussian Process 和样条等负对照，清楚展示样本外变常数、向中心回落或边界反向下降的问题；
- 把目标变换敏感性作为核心风险，指出原值 Ridge 与对数 Ridge/BayesianRidge 的 2030 结果差异远大于超参数差异。

局限：

- 游客量在 2020—2022 年没有官方标签，因此疫情哑变量对游客量的冲击效应不能由观测数据识别；收入也只有 2021 年一个疫情期标签；
- 恢复期实际只有 2023、2024 两个标签，恢复水平项高度依赖这两个年份；
- 原值 Ridge 假定未来延续固定绝对增量，对数 Ridge 假定延续固定百分比增长，二者都是结构假设，不存在数据自动证明哪一个长期正确；
- BayesianRidge 条件区间没有覆盖目标变换、疫情类型、政策变化和 data 缺失机制，不能写成总不确定性 95% 区间。

因此，原值 Ridge 适合作为低方差数据基准，但不应作为唯一预测。

6.2 传统统计试跑报告

优点：

- 对证据等级、指标口径、累计约束和二手数据的界限处理较严谨；
- 采用参数较少的对数线性断点模型，避免在 12 个有效样本上选择高阶 ARIMA；
- 能给出趋势、断点项、残差诊断和条件预测区间；
- 政策锚定情景清晰区分数据预测与规划假设，适合论文政策分析。

局限：

- 3.39%—3.57% 的 MAPE 是样本内拟合误差，不能与机器学习报告的滚动 sMAPE 直接比较；
- 2030 年游客量 5982.6 万人次、收入 619.0 亿元来自疫情前年增长率继续保持了强假设，更接近乐观恢复上界；
- 2025 年政府目标不是实际值，以目标为锚的路径只能称为规划情景；
- 新增宏观变量虽补齐到 16 年，但 2019 年口径断点和未来外生变量未知，使高维 ARIMAX 仍不稳健。

因此，对数断点模型适合历史解释和乐观上界，不宜作为唯一基准。

七、最终模型选择建议

问题 1：历史规律与结构冲击

主模型建议采用**质量分层的稳健分段对数回归**：分别设置疫情前趋势、2020—2022 冲击状态、2023 以后恢复水平，并加入 2019 年宏观口径断点。严格观测层用于主估计，补全层和上下界用于敏感性。若需要创新，可用贝叶斯局部线性趋势或隐马尔可夫状态切换验证阶段划分，但不能增加过多自由参数。

问题 2：2026—2030 预测

建议采用三路径而非唯一曲线：

- 1. **数据驱动基准**：原值 Ridge，特征仅含可向未来延伸的时间趋势和恢复状态；当前 2030 结果约为 3941.1 万人次、298.5 亿元；
- 2. **政策规划基准**：以透明政策假设形成路径，现有情景 2030 约为 3548.9 万人次、339.4 亿元；
- 3. **乐观恢复上界**：对数断点/BayesianRidge，2030 约为 5971—5983 万人次、615—619 亿元。

最终报告应以 expanding-origin 滚动回测选择数据基准，同时把跨模型分歧作为结构不确定性。不要把三个模型简单平均为一个“精确答案”；可以用滚动误差的倒数加权，但政策情景和统计模型应保持不同语义。

问题 3：政策敏感性与方案决策

主模型建议采用：

$$R_t = \frac{V_t S_t}{10000},$$

并将游客量增长、人均消费、过夜率、政策投入效率和外部冲击设置为区间或三角分布，通过拉丁超立方 Monte Carlo 生成情景分布，再用 PRCC 或 Sobol 指标排序关键杠杆。现有数据无法可靠估计“旅游投入增加 1% 带来多少游客”的因果弹性，因此政策投入系数只能是文献/专家区间；拿到相似区县面板和项目投产数据后，再升级为 DID、合成控制或贝叶斯网络。

八、论文中必须保留的表述边界

- “建模补全值”不能写成“处理后的真实值”或“官方数据”；
- 2019 年宏观下降应称为“显著口径/核算断点”，不能直接解释为实体经济下降 42%；
- 样本内 MAPE、滚动 sMAPE 和政策情景不能放在同一排名中比较；
- 条件模型区间不能覆盖模型结构、目标变换和政策变化，不能称为总不确定性区间；
- 标准化、变量选择和超参数调优必须在每个训练窗内重新拟合；
- 深度学习、复杂树模型和高阶 ARIMAX 在当前年度样本下不适合作为主模型。

配套 Excel 工作簿包含严格原始层、缺失补全、建模主表、异常检测、原生图表、转换说明、供给辅助变量、数据补充路线和模型建议；CSV 主表可直接由 Python、R、MATLAB 或 Stata 读取。