

# 蓟州区旅游经济发展趋势预测与对策分析

## 摘要

对于问题一,  
对于问题二,  
对于问题三,  
对于问题四,  
最后,

关键词： 关键词； 关键词； 关键词； 关键词； 关键词

## 目录

|                       |    |
|-----------------------|----|
| 一、 问题背景与重述 .....      | 4  |
| 二、 问题分析 .....         | 5  |
| 三、 模型假设 .....         | 6  |
| 四、 符号说明 .....         | 7  |
| 五、 数据预处理 .....        | 7  |
| 六、 问题一的模型的建立和求解 ..... | 11 |
| 七、 问题二的模型的建立和求解 ..... | 12 |
| 八、 问题三的模型的建立和求解 ..... | 13 |
| 九、 问题四的模型的建立和求解 ..... | 14 |
| 十、 模型的分析与检验 .....     | 15 |
| 十一、 模型的评价、改进与推广 ..... | 16 |
| A 附录文件列表 .....        | 17 |

# 一、问题背景与重述

## 1.1 问题背景

蓟州区依托山岳景观、历史文化遗产以及毗邻京津两大客源市场的区位优势，已经形成以观光游、休闲度假和乡村旅游为主体的区域旅游产业体系。随着居民出游方式由单一景区游览逐步转向短途休闲、文化体验和多业态消费，旅游业对交通接驳、住宿供给、公共服务和产业协同的要求同步提高。与此同时，当地的旅游统计仍存在年份缺失、指标名称相同而统计口径不同、名义收入受价格变动影响等问题；2020年至2022年的新冠疫情事件又造成了明显的非正常波动。若直接依据少数年份的同比增长率进行外推，容易高估长期增长能力或误判恢复速度。因此，有必要在统一数据口径的基础上，将历史规律、突发冲击和政策条件共同纳入预测与决策框架。

## 1.2 问题重述

基于此，本题既要建立能够刻画趋势与结构突变的统计模型，也要通过情景分析描述政策实施程度和外部环境变化所带来的条件性差异。围绕这一目标，本文将原问题提炼为以下三个相互衔接的子问题：

**问题 1：历史数据治理与发展规律识别。**整合 2010 年至 2025 年间蓟州区旅游接待规模、旅游综合收入及相关经济社会指标，处理缺失记录、单位差异、价格因素和统计口径变化；利用可视化、增长率分解与结构突变识别分析长期趋势及疫情冲击，并构造一个结构清晰的基准增长模型，评价其适用区间和局限性。

**问题 2：旅游客流与综合收入的中期预测。**在短样本和异常冲击并存的条件下，从时间序列模型、动态回归模型及其组合形式中选择合适方法，完成参数估计、显著性检验和残差诊断；据此预测 2026 年至 2030 年的游客接待量和旅游综合收入，给出点预测及 95% 预测区间，并在统一验证区间内与问题 1 的基准模型比较，从而衡量模型的性能。

**问题 3：不确定环境下的情景推演与政策决策。**以问题 2 的预测模型为基石，把政策投入、京津客源市场变化和旅游新业态发展速度等不稳定因素转化为可量化的参数，构建基准、乐观和悲观三类条件情景；通过敏感性分析，识别其中哪些参数对旅游经济的发展最为关键，最终形成若干包含实施力度、作用期限、预期增量和监测指标的政策建议。

## 二、问题分析

**总体思路。**本题按照“可信数据构建—阶段规律识别—组合预测—情景模拟与稳健决策”的主线展开。首先依据数据来源、证据等级和统计口径建立可追溯的年度长表，显式保留缺失、修订及制度断点；其次从游客规模与人均旅游消费两个维度刻画常态增长、外生冲击和恢复阶段；继而利用相互补充的趋势模型、指数平滑模型和状态空间模型预测 2026 年至 2030 年的发展路径，并以滚动起点验证确定组合权重；最后将政策作用分解为“深层驱动—中间能力—客流与消费结果”，通过情景模拟和风险约束优化形成可执行的政策组合。三个问题依次完成“认清历史—推演未来—选择行动”，前一问的清洗结果、阶段划分和参数区间均作为后一问的输入。

### 2.1 问题 1 分析

**关键矛盾：**年度样本短、来源版本多，且旅游直接收入与综合收入、年度实际与规划目标不可混接；2020 年至 2022 年又是强行政干预期，缺失或低位观测不代表常态旅游规律。**解题框架：**先以“后版修订值优先、实际值优先、同口径成序列”为原则完成数据治理，再用对数趋势、增长率和人均消费识别发展阶段及结构断点。**核心步骤：**建立来源可追溯长表，生成观测掩码和口径断点标记；在 2010 年至 2019 年的常态样本上估计基准趋势，对 2020 年至 2022 年只作冲击诊断而不作线性插值；结合 2023 年至 2024 年的恢复观测判断新阶段斜率，并以残差、断点检验和经济含义共同评价模型。流程为：多源数据输入 → 版本与口径筛选 → 缺失机制标注 → 常态趋势估计 → 断点与恢复识别 → 规律解释。

### 2.2 问题 2 分析

**关键矛盾：**预测期为五年，而严格可比的旅游样本有限，单一复杂模型容易过拟合，单一简单模型又难以反映冲击后的恢复速度。**解题框架：**分别对游客量与旅游综合收入建立分段对数趋势、缺失感知的阻尼 Holt 模型和局部线性状态空间模型，以结构解释、平滑外推和随机状态更新形成互补。**核心步骤：**先按问题 1 确定的常态段、冲击段和恢复段构造训练序列；再对三个候选模型进行参数估计与残差诊断；采用滚动起点法比较 MAE、RMSE 和 sMAPE，并按验证误差反比分配组合权重；最后通过残差自助法和参数抽样给出点预测及区间预测。流程为：阶段化序列 → 候选模型估计 → 滚动验证 → 组合赋权 → 不确定性传播 → 2026–2030 年预测。

### 2.3 问题 3 分析

**关键矛盾：**政策变量难以直接观测，且客流扩张、消费提升、承载能力和财政风险之间存在权衡，不能仅凭单因素弹性给出结论。**解题框架：**以收入恒等式“综合收入 =

游客量 × 人均消费”为桥梁，将文化品牌、过夜体验、农文旅融合、产业链新业态以及基础设施与风险治理等政策投入映射为客流增量和消费增量，并建立含预算、承载力与风险约束的多目标决策模型。**核心步骤：**依据历史波动、规划边界和文献机制设定参数分布；运用拉丁超立方抽样生成基准、积极和审慎情景；计算各政策组合的收入、质量与下行风险；以期望收益和发展质量最大、条件风险价值最小为目标求解稳健方案，并通过敏感性分析识别关键政策杠杆。流程为：**组合预测基线 → 政策机制量化 → 情景抽样 → 收益与风险计算 → 多目标优化 → 稳健性检验与建议。**

### 三、模型假设

为使短样本下的趋势识别、预测和政策优化具有明确边界，作如下假设。

1. **同口径观测可比假设。****假设内容：**经单位、指标含义、行政范围和发布版本核对后，同一口径下的游客量与旅游综合收入具有跨期可比性；直接收入不与综合收入拼接。**合理性依据：**数据长表保留了指标范围、证据等级和初值/修订值，且优先采用后版年鉴或政府报告中的年度实际值。**模型影响：**保证趋势系数具有一致经济含义，同时将无法桥接的口径变化转化为断点变量而非虚假增长。
2. **行政干预期非正常生成机制假设。****假设内容：**2020年至2022年的旅游活动受强外生行政干预，其游客量与综合收入不服从2010年至2019年的常态增长机制；缺失值保持为空，已观测的2021年收入仅用于冲击识别。**合理性依据：**该阶段的人员流动和经营条件由外部限制主导，将其插值为常态值或直接记为零均缺乏统计依据。**模型影响：**避免低估长期增长率，模型通过观测掩码、干预变量和状态转移跨越该时段。
3. **恢复期局部稳定假设。****假设内容：**在未发生同量级新冲击的条件下，2023年至2024年所反映的恢复方向与2010年至2019年的长期机制共同约束2026年至2030年的演化区间。**合理性依据：**预测期仅五年，且模型使用阻尼趋势和情景扰动限制远期指数外推。**模型影响：**使历史信息能够外推，同时通过参数抽样和预测区间保留恢复速度的不确定性。
4. **政策作用的中介与边际递减假设。****假设内容：**政策投入主要通过品牌吸引力、接待能力、停留时间和产业融合等中间能力影响游客量与人均消费，且边际效果随投入增加而递减。**合理性依据：**旅游政策通常不能直接等额转化为收入，短样本下采用低维中介路径可减少共线性，也符合基础设施和营销投入的边际收益规律。**模型影响：**政策响应函数可保持单调但非线性，防止优化结果把全部预算集中于单一政策。
5. **情景内随机扰动可模拟假设。****假设内容：**给定宏观与政策情景后，未解释扰动的条件均值为零，其波动范围可由滚动预测残差和参数分布近似。**合理性依据：**残差诊断与自助抽样不要求总体严格正态，适合样本较短且参数不确定的情形。**模型影响：**

可统一生成预测区间、情景分布和 CVaR 下行风险，但结论仅在所设情景边界内成立。

四、符号说明

表 1 主要符号说明

| 符号                                                       | 含义                                            | 单位     |
|----------------------------------------------------------|-----------------------------------------------|--------|
| $t, T, T^*$                                              | 年份索引、官方旅游主样本末年和辅助证据末年； $T = 2024, T^* = 2025$ | 年      |
| $V_t$                                                    | 第 $t$ 年旅游接待量                                  | 万人次    |
| $R_t$                                                    | 第 $t$ 年旅游综合收入（官方当年价口径）                        | 亿元     |
| $S_t$                                                    | 第 $t$ 年人均旅游综合消费， $S_t = 10^4 R_t / V_t$       | 元/人次   |
| $Y_t^{(j)}$                                              | 指标 $j$ 的对数序列， $j \in \{V, R\}$                | 无量纲    |
| $M_t^{(j)}$                                              | 指标 $j$ 在第 $t$ 年的观测掩码，有值为 1，否则为 0              | 无量纲    |
| $D_t^{\text{cov}}, D_t^{\text{rec}}, D_t^{\text{scope}}$ | 行政干预、恢复阶段和统计口径断点指示变量                          | 无量纲    |
| $G_t, Q_t$                                               | 第 $t$ 年地区生产总值、第三产业增加值                         | 亿元     |
| $\ell_t, b_t$                                            | 状态空间或 Holt 模型在第 $t$ 年的局部水平与趋势状态               | 依模型而定  |
| $\hat{Y}_{t T}^{(m)}, w_m$                               | 模型 $m$ 的条件预测及其组合权重， $\sum_m w_m = 1$          | 无量纲    |
| $\theta^{(s)}$                                           | 情景 $s$ 下的需求、消费、政策响应和风险参数向量                    | 依参数而定  |
| $\mathbf{x} = (x_1, \dots, x_K)$                         | $K$ 类政策工具的投入或资源配置向量                           | 亿元或指数  |
| $B$                                                      | 可用于政策组合的预算上限                                  | 亿元     |
| $C_t$                                                    | 第 $t$ 年旅游承载或高质量发展约束指标                         | 无量纲    |
| $\text{CVaR}_\alpha$                                     | 置信水平 $\alpha$ 下政策方案的条件尾部损失                    | 亿元     |
| $\varepsilon_t$                                          | 第 $t$ 年的随机扰动项                                 | 与因变量相同 |

五、数据预处理

5.1 数据来源与主样本界定

数据覆盖 2010 年至 2025 年，来源包括蓟州区政府工作报告、统计公报及年鉴回列值，并以“年度汇总表 + 指标长表”的形式保存每条记录的来源、证据等级、统计范围和发布状态。16 个年度位置中，游客量和旅游综合收入各有 12 个优选值，GDP 与第三产业增加值均为 16 年全覆盖。考虑旅游数据的证据质量，本文不直接使用旧版汇总工作簿中的二手补充值，而以政府扩充版 CSV 长表为准。主样本筛选规则见下表。

表 2 数据筛选与用途划分

| 数据类别    | 选取规则                                               | 建模用途                  |
|---------|----------------------------------------------------|-----------------------|
| 旅游年度实际  | 保留 annual 且状态为 observed、revised 或可核验约数；同年多版本取后版修订值 | 游客量与综合收入的趋势识别、预测与模型检验 |
| 目标与累计值  | 排除 target 和 five_year_total, 不将五年累计值拆分为年度值         | 仅作为政策情景上界或总量一致性约束     |
| 宏观指标    | GDP、第三产业增加值优先采用 final、revised 或 yearbook 状态        | 解释背景、口径检验及外生变量稳健性模型   |
| 低层级与推导值 | 2010 年收入反推值、2015 年附件值及 2025 年二手信息单列                | 不进入严格主估计，只用于敏感性和外部校验  |

5.2 缺失值与行政干预期处理

首先定义观测掩码

$$M_t^{(j)} = \begin{cases} 1, & \text{第}t\text{年指标}j\text{存在合格年度实际值,} \\ 0, & \text{缺失、仅有目标值或仅有累计值,} \end{cases} \quad j \in \{V, R\}.$$

普通时间序列插值要求缺口两侧服从近似相同的生成机制，但 2020 年至 2022 年受强行政干预，显然不满足这一前提。因此，本文**不对该三年的游客量和综合收入作均值、线性或 KNN 填充，也不将空白视为零**：2020 年两项指标均保持缺失，2021 年仅保留已核验的综合收入 110 亿元并标注为冲击观测，2022 年两项指标继续保持缺失。建模时，分段趋势模型只利用合格观测，Holt 模型按实际日历间隔推进但在缺失年跳过观测更新，状态空间模型则通过缺失感知似然完成状态传播。由此，三年仍形成必要的时间过渡，却不会被误当成正常旅游样本。

其余关键缺口同样分层处理：2016 年没有同口径综合收入，不以直接收入的固定倍数替代；2025 年政府资料只给出目标和五年累计值，媒体所述 2691 万人次及“收入突破 200 亿元”仅作为辅助区间证据。因此严格预测样本截止于 2024 年，记为  $T = 2024$ ，2025 年记为辅助证据年  $T^*$ 。

5.3 重复值、口径断点与异常值处理

同一年出现初值、精确值和后续回列修订值时，按照“年度实际优先于目标、后版修订优先于当期初值、精确值优先于工作报告约数”的顺序选择，同时在长表中保留原

记录以便追溯。旅游直接收入与旅游综合收入属于不同指标，绝不按经验比例拼接。对于 2018 年至 2019 年的 GDP 及相关指标明显跳变，依据来源说明将其视为核算范围或年鉴修订造成的口径断点，设置  $D_t^{\text{scope}}$  或在相应外生模型中剔除，避免将统计变化解释为真实经济冲击。

由于原序列具有明显上升趋势且样本很短，直接对水平值使用 Z-score 容易把早期低值误判为异常。本文先在同一阶段内拟合对数趋势，令残差为  $e_t = Y_t - \hat{Y}_t$ ，再采用稳健标准分数

$$z_t^* = \frac{0.6745(e_t - \text{median}(e))}{\text{MAD}(e)}, \quad |z_t^*| > 3.5$$

作为主要异常判据，并用 IQR 箱线图复核。检测到的数据首先回查原始来源，而非机械删除或缩尾。2021 年综合收入的低位具有明确外生原因，故保留在冲击诊断层、排除于常态趋势估计层；其余经核验的极端值若为统计口径变化，则通过断点变量处理。最终主样本不因单纯数值大小删除任何官方实际观测。

#### 5.4 变量转换与派生指标

游客量统一为万人次，综合收入、GDP 和第三产业增加值统一为亿元。为减弱异方差并将趋势系数解释为近似增长率，对正值序列作

$$Y_t^{(V)} = \ln V_t, \quad Y_t^{(R)} = \ln R_t.$$

为区分“游客规模扩张”与“消费质量提升”，仅在  $V_t$  和  $R_t$  同时存在且口径一致时计算

$$S_t = \frac{10^4 R_t}{V_t},$$

其中  $S_t$  的单位为元/人次。同比增长率只在同一制度阶段且相邻两年均有合格观测时计算，禁止将 2019 年与 2023 年直接连成单年同比。旅游收入主序列保持官方当年价口径；若后续补入可核验的居民消费价格指数，则仅在稳健性分析中按  $R_t^{\text{real}} = R_t I_{\text{base}} / I_t$  转为可比价，不人为生成价格指数。

对进入动态回归、情景模拟或优化模型的连续解释变量，使用训练期均值和标准差进行标准化：

$$Z_{kt} = \frac{X_{kt} - \bar{X}_{k,\text{train}}}{s_{k,\text{train}}}.$$

标准化参数只由训练窗口计算并原样作用于验证期，防止未来信息泄漏；树模型或仅含时间趋势的模型不作无必要的归一化。

#### 5.5 预处理结果与验证方式

预处理后形成三层数据：第一层为证据等级较高的年度实际主样本；第二层为冲击观测、恢复期观测和口径断点标记；第三层为推导值、低层级附件、目标及二手阈值构成的敏感性样本。具体处理结果汇总如下。



表 3 关键数据问题的处理结果

| 问题              | 处理结果                     | 理由及影响                         |
|-----------------|--------------------------|-------------------------------|
| 2020–2022 年旅游数据 | 保留空白或冲击观测，不插值            | 属外生行政干预期；只推进时间状态，不参与常态斜率估计    |
| 2016 年综合收入缺失    | 保留空白                     | 直接收入与综合收入不是同一口径，固定倍数换算会引入伪精度  |
| 2025 年旅游实际缺失    | 主模型截止 2024 年，2025 年仅辅助校验 | 现有政府资料为目标/累计，二手报道不足以替代官方精确年度值 |
| 同年多版本           | 优先后版修订和精确实际值             | 减少发布初值偏差，同时保留全部来源记录以备追溯       |
| 异常和断点           | 稳健残差检测 + 来源复核；不机械删除      | 将真实冲击、统计断点与录入错误区分处理           |

鉴于样本量有限，模型评估不采用随机划分，而采用滚动起点验证：每次仅用预测时点之前的信息估计模型，再对下一期观测计算误差。该处理既保持时间顺序，也使模型选择、组合权重和区间覆盖率均建立在真实的样本外预测逻辑上。

## 六、 问题一的模型的建立和求解

6.1 具体分析

6.2 模型准备

6.3 模型建立

6.4 模型求解

## 七、 问题二的模型的建立和求解

### 7.1 具体分析

### 7.2 模型准备

### 7.3 模型建立

### 7.4 模型求解

## 八、 问题三的模型的建立和求解

### 8.1 具体分析

### 8.2 模型准备

### 8.3 模型建立

### 8.4 模型求解

## 九、 问题四的模型的建立和求解

### 9.1 具体分析

### 9.2 模型准备

### 9.3 模型建立

### 9.4 模型求解

## 十、模型的分析与检验

### 10.1 灵敏度分析

### 10.2 误差分析

## 十一、 模型的评价、改进与推广

### 11.1 模型的优点

- 优点 1
- 优点 2
- 优点 3

### 11.2 模型的缺点

- 缺点 1
- 缺点 2

### 11.3 模型的改进

### 11.4 模型的推广

## 参考文献

- [ ] HYNDMAN R J, ATHANASOPOULOS G. Forecasting: Principles and practice[M/OL]. 3rd ed. Melbourne, Australia: OTexts, 2021. <https://otexts.com/fpp3/>.
- [ ] UN Tourism. World tourism barometer[R/OL]. Madrid: UN Tourism, 2024. <https://www.unwto.org/un-tourism-world-tourism-barometer-data>.



## 人工智能工具使用声明

本参赛队在论文准备过程中使用了人工智能工具，现作如下披露：使用工具为 OpenAI Codex，主要用于论文结构梳理、数据处理方案讨论、 $\text{\LaTeX}$  排版及语言表达优化。所有数据来源、统计口径、模型设定、程序代码、计算结果和论文结论均由参赛队成员逐项核验并作最终决定，未将未经人工复核的生成内容直接作为论文结论。若后续使用其他人工智能工具，参赛队将在提交前按照联赛《人工智能工具使用规定》补充工具名称、使用环节、主要用途及人工核验方式。

## 附录 A 支撑材料文件列表

支撑材料压缩包中的文件应与下表及论文正文保持一致；提交前须确认所有程序能够独立运行并复现论文中的主要结果。

| 文件名         | 功能描述             |
|-------------|------------------|
| 1. 数据预处理.py | 数据清洗、缺失标记与变量转换程序 |
| q1.m        | 问题一模型程序          |
| q2.py       | 问题二程序代码          |
| q3.c        | 问题三程序代码          |
| q4.cpp      | 辅助优化或扩展分析程序      |

## 附录 B 完整源程序代码

### 2.1 数据预处理程序

```

1 import pandas as pd
2 from sklearn.preprocessing import MinMaxScaler, LabelEncoder
3
4 # 读取数据集
5 file_path = r"C:\Users\18344\Desktop\机器学习模型实战\分类模型实战演示\附件\heart.csv"
6 df = pd.read_csv(file_path)
7
8 # 1. 识别缺失值
9 print("缺失值检查:")
10 print(df.isnull().sum())
11
12 # 填补缺失值 (用均值填补数值型变量)
13 df['RestingBP'] = df['RestingBP'].fillna(df['RestingBP'].mean())
14 df['Cholesterol'] = df['Cholesterol'].fillna(df['Cholesterol'].mean())
15 df['MaxHR'] = df['MaxHR'].fillna(df['MaxHR'].mean())
16
17
18 # 再次检查是否存在缺失值
19 print("\n填补缺失值后缺失值检查:")
20 print(df.isnull().sum())
21
22 # 2. 异常值处理
23 # 使用IQR法处理异常值
24 Q1 = df[['RestingBP', 'Cholesterol', 'MaxHR']].quantile(0.25)
25 Q3 = df[['RestingBP', 'Cholesterol', 'MaxHR']].quantile(0.75)
26 IQR = Q3 - Q1
27
28 # 定义异常值的范围
29 lower_bound = Q1 - 1.5 * IQR
30 upper_bound = Q3 + 1.5 * IQR
31
32 # 去除异常值

```

```

33
34 df['RestingBP'] = df['RestingBP'].fillna(df['RestingBP'].mean())
35 df['Cholesterol'] = df['Cholesterol'].fillna(df['Cholesterol'].mean())
36 df['MaxHR'] = df['MaxHR'].fillna(df['MaxHR'].mean())
37
38
39 print("\n数据去除异常值后的样本数:", df.shape[0])
40
41 # 3. 处理重复值
42 print("\n重复值检查:")
43 print(df.duplicated().sum())
44
45 # 删除重复值
46 df = df.drop_duplicates()
47
48 print("\n删除重复值后的样本数:", df.shape[0])
49
50 # 4. 极差标准化: 对RestingBP, Cholesterol, MaxHR进行标准化
51 scaler = MinMaxScaler()
52 df[['RestingBP', 'Cholesterol', 'MaxHR']] = scaler.fit_transform(df[['RestingBP', 'Cholesterol', 'MaxHR']])
53
54 # 5. 标签编码: 对分类特征进行标签编码
55 label_columns = ['Sex', 'ChestPainType', 'ExerciseAngina', 'RestingECG', 'ST_Slope']
56 le = LabelEncoder()
57
58 for col in label_columns:
59     df[col] = le.fit_transform(df[col])
60
61 # 输出预处理后的数据集
62 print("\n数据预处理后的前5行数据:")
63 print(df.head())
64
65 # 保存预处理后的数据集
66 output_path = r"C:\Users\18344\Desktop\机器学习模型实战\分类模型实战演示\分类模型实战\code\heart_preprocessed.csv"
67 df.to_csv(output_path, index=False)
68
69 print(f"\n预处理后的数据集已保存至: {output_path}")

```

## 2.2 问题一程序

```
1 disp("Hello World!")
```

## 2.3 问题二程序

```
1 print("Hello World!")
```

## 2.4 问题三程序

```
1 #include <stdio.h>
2
```

```
3 int main()
4 {
5     printf("Hello World!");
6     return 0;
7 }
```

## 2.5 辅助优化程序

```
1 #include <bits/stdc++.h>
2 using namespace std;
3
4 int main()
5 {
6     cout << "Hello World!" << endl;
7     return 0;
8 }
```